

Master de Santé Publique

M2 SDS — Science des données de santé

Le master Science des données de Santé forme les étudiants à l'analyse des données, en particulier des données de grande dimension, et avec une attention particulière accordée aux données de santé (génomique, études prédictives, pharmaco-épidémiologie...).

Premier semestre

Bases en Génétique et en Biostatistiques	1 ECTS
Programmation en Python	3 ECTS
Programmation en R	3 ECTS
Statistiques multivariées	5 ECTS
Apprentissage automatique	4 ECTS
Recherche bio-médicale, études prédictives, analyse de survie	4 ECTS
Études d'association et de liaison en génétique humaine	3 ECTS
Logiciels	2 ECTS
Méthodes et applications en pharmaco épidémiologie	1 ECTS
Analyse Causale	3 ECTS
Séminaires	1 ECTS

Second semestre

Stage	30 ECTS
-------	---------

Équipe pédagogique et intervenants : Philippe Broët, Mohammed Sedki, Hervé Perdry, Émeline Courtois, Valérie Chaudru, Emmanuelle Bouzigon, Aurélie Cobat, Claire Dandine-Roulland, Jacqueline Milet, Patricia Jeannin, Anne-Louise Leutenegger, Anne Thiébaud.

Bases en Biostatistiques et en Génétique

Responsable : Hervé Perdry et Valérie Chaudru

Objectifs

Donner ou redonner des bases en statistiques et en génétique.

Programme

Génétique formelle, éléments de génétique moléculaire et génétique humaine.

Calcul des probabilités : Probabilités, Probabilités conditionnelles, théorème de Bayes

Variables aléatoires : densité, fonction de répartition, espérance, variance.

Estimateurs et tests statistiques.

Examen

Évaluation par devoir à la maison.

Horaires

Statistiques 1	8 octobre	13h30-16h30
Statistiques 2	9 octobre	13h30-16h30
Statistiques 3	10 octobre	13h30-16h30
Statistiques 4	14 octobre	9h30-12h30
Génétique 1	23 octobre	9h30-12h30
Génétique 2	23 octobre	13h30-16h30

Programmation en Python

Responsable : Mohammed Sedki

Objectifs

Ce cours est une brève introduction à l'environnement et langage de programmation Python. Il vise essentiellement à familiariser l'étudiant avec les bibliothèques de bases NumPy, pandas, SciPy et Matplotlib.

Programme

- L'environnement python: ses caractéristiques principales et environnement de programmation spyder et notebooks
- Introduction à Numpy: type ndarray et indexation de base (slices), opérations de base, fonctions de base
- Bonnes pratiques de programmation: PEP8, tests unitaires, structuration des programmes
- Numpy avancé : indexation avancée (avec des entiers et booléens), règles de diffusion, etc
- Visualisation avec Matplotlib
- Manipulation de fichiers de données (pandas...)
- Si le temps le permet : découverte de la bibliothèque scikit-learn

Examen

Devoir à la maison / examen en temps limité

Horaires

Séance 1	8 octobre	9h30-12h30
Séance 2	9 octobre	9h30-12h30
Séance 3	15 octobre	13h30-16h30
Séance 4	16 octobre	13h30-16h30
Séance 5	21 octobre	13h30-16h30
Séance 6	22 octobre	9h30-12h30
Séance 7	29 octobre	9h30-12h30

Programmation en R

Responsable : Hervé Perdry

Objectifs

- utiliser R pour manipuler efficacement des jeux de données
- être capable de programmer une nouvelle méthode statistique en R

Programme

- Objets de R : vecteurs, data frames, matrices
- Lecture de données avec `read.table`
- Boucles `for` et `while`, création de fonctions
- Programmation vectorisée (`apply`, `lapply`, etc)
- Méthodes d'optimisation : maximisation numérique d'une vraisemblance
- Méthodes de Monte-Carlo : évaluation empirique de la puissance d'un test statistique, etc.

Examen

Devoir à la maison / examen en temps limité

Horaires

Séance 1	10 octobre	9h30-12h30
Séance 2	14 octobre	13h30-16h30
Séance 3	17 octobre	13h30-16h30
Séance 4	24 octobre	9h30-12h30
Séance 5	30 octobre	13h30-16h30
Séance 6	7 novembre	9h30-12h30
Séance 7	7 novembre	13h30-16h30

Statistiques multivariées

Responsables : Hervé Perdry, Mohammed Sedki

Objectifs

Compléter la formation de base en statistiques.

Programme

- Matrices et vecteurs
- Fonctions et lois multivariées
- Vraisemblance : estimation et test
- Ré-échantillonnage
- Le modèle linéaire
- Introduction au modèle linéaire généralisé et au modèle linéaire mixte

Examen

Devoir à la maison / examen en temps limité

Horaires

Séance 1 – Matrices et vecteurs (HP)	15 octobre	9h30-12h30
Séance 2 – Fonctions multivariées	16 octobre	9h30-12h30
Séance 3 – Lois multivariées	17 octobre	9h30-12h30
Séance 4 – Exemple et TD	21 octobre	9h30-12h30
Séance 5 – Vraisemblance 1 (MS)	31 octobre	13h30-16h30
Séance 6 – Vraisemblance 2	5 novembre	9h30-12h30
Séance 7 – Vraisemblance 3	18 novembre	9h30-12h30
Séance 8 – Ré-échantillonnage	19 novembre	9h30-12h30
Séance 9 – Exemples et TD	21 novembre	13h30-16h30
Séance 10 – Modèle linéaire 1 (HP)	25 novembre	9h30-12h30
Séance 11 – Modèle linéaire 2	26 novembre	13h30-16h30
Séance 12 – Modèle linéaire généralisé 1	28 novembre	9h30-12h30
Séance 13 – Modèle linéaire généralisé 2	4 décembre	9h30-12h30
Séance 14 – Exemples et TD	6 janvier	13h30-16h30
Séance 15 – Optimisation, EM	7 janvier	13h30-16h30
Séance 16 – Optimisation, EM	8 janvier	13h30-16h30
Séance 17 – Optimisation, EM	9 janvier	13h30-16h30

Apprentissage automatique

Responsable : Mohammed Sedki

Objectifs

L'objectif de cette UE est de sensibiliser et familiariser l'étudiant avec les idées, modèles et protocoles à la base de la science des données.

Programme

- Introduction aux deux problèmes d'apprentissage statistique : régression et classification
- Contrôle de la complexité d'un modèle : choix des hyper-paramètres par validation croisée
- Méthodes de régression linéaire et logistique régularisées
- Arbres de décisions pour la régression et la classification
- Agrégation de modèles : forêts aléatoires et gradient boosting
- SVM et réseaux de neurones
- Apprentissage non supervisé

Examen

Devoir à la maison / examen en temps limité

Horaires

Séance 1	26 novembre	9h30-12h30
Séance 2	27 novembre	9h30-12h30
Séance 3	3 décembre	9h30-12h30
Séance 4	5 décembre	9h30-12h30
Séance 5	9 décembre	9h30-12h30
Séance 6	9 décembre	13h30-16h30
Séance 7	10 décembre	9h30-12h30
Séance 8	11 décembre	9h30-12h30
Séance 9	11 décembre	13h30-16h30
Séance 10	12 décembre	13h30-16h30

Recherche bio-médicale, études prédictives, analyse de survie

Responsable : Philippe Broët

Objectifs

Programme

- Séance 1 : introduction
- Séances 2-4 : techniques de pre-processing
- Séances 5-6 : association
- Séances 7-9 : prédiction
- Séances 10-14 : analyse de survie

Examen

Ce module est évalué par un devoir à la maison (« mini-projet »).

Horaires

Séance 1	22 octobre	13h30-16h30
Séance 2	24 octobre	13h30-16h30
Séance 3	28 octobre	13h30-16h30
Séance 4	29 octobre	13h30-16h30
Séance 5	4 novembre	13h30-16h30
Séance 6	5 novembre	13h30-16h30
Séance 7	18 novembre	13h30-16h30
Séance 8	19 novembre	13h30-16h30
Séance 9	20 novembre	9h30-12h30
Séance 10	27 novembre	13h30-16h30
Séance 11	3 décembre	13h30-16h30
Séance 12	4 décembre	13h30-16h30
Séance 13	5 décembre	13h30-16h30

Études d'association et de liaison en génétique humaine

Responsable : Hervé Perdry

Objectifs

Présenter les méthodes utilisées pour l'analyse de données génétiques, qu'il s'agisse de données familiales ou en population, de l'étude de traits quantitatifs ou binaires.

Programme

1. Introduction à la génétique des populations, équilibre de Hardy Weinberg
2. Liaison et recombinaison. Déséquilibre de liaison.
3. Consanguinité et population structurée.
4. Notions de génétique quantitative.
5. Analyse de liaison (LOD score) (Valérie Chaudru)
6. Études d'association. (Valérie Chaudru)
7. Études GWAS. (Emmanuelle Bouzigon)
8. Randomisation Mendélienne. (Emmanuelle Bouzigon)
9. Analyse de variants rares. (Aurélie Cobat)
10. Interaction Gène-Environnement. (Claire Dandine)

Examen

Devoir à la maison / examen en temps limité

Horaires

Séance 1	28 octobre	9h30-12h30
Séance 2	30 octobre	9h30-12h30
Séance 3	31 octobre	9h30-12h30
Séance 4	4 novembre	9h30-12h30
Séance 5	6 novembre	9h30-12h30
Séance 6	6 novembre	13h30-16h30
Séance 7	20 novembre	9h30-12h30
Séance 8	21 novembre	9h30-12h30
Séance 9	25 novembre	13h30-16h30
Séance 10	18 décembre	9h30-12h30

Logiciels

Responsable : Hervé Perdry

Objectifs

Présenter le système d'exploitation Linux, ainsi que des logiciels ou des packages R et Python spécifiques à l'analyse de données.

Programme

- Système d'exploitation linux
- Logiciels plink et locuzoom
- Bases de données génétiques (Biomart)
- Package R Gaston
- Package R Fantasio

Examen

Devoir à la maison

Séances

Séance 1. Intro à linux/unix (HP)	2 décembre	9h30-12h30
Séance 2. Gaston (Claire Dandine)	2 décembre	13h30-16h30
Séance 3. Intro à linux/unix (HP)	10 décembre	13h30-16h30
Séance 4. Plink (Patricia Jeannin)	12 décembre	9h30-12h30
Séance 5. Analyse post GWAS avec FUMA (Jacqueline Milet)	16 décembre	13h30-16h30
Séance 6. Package Fantasio (Anne-Louise Leutenegger)	17 décembre	13h30-16h30
Séance 7. Bases de données (Claire Dandine)	18 décembre	9h30-12h30
Séance 8. Intro à linux/unix (HP)	19 décembre	9h30-12h30

Méthodes et applications en pharmaco-épidémiologie

Responsable : Anne Thiébaut

Objectifs

- Appréhender d'autres sources de données de grande dimension : les bases médico-administratives
- Connaître les principes et les spécificités de la pharmaco-épidémiologie pour traiter ces données
- Connaître les bases méthodologiques des études de pharmaco-épidémiologie
- Savoir lire, interpréter et critiquer les résultats d'une étude de pharmaco-épidémiologie

Programme

- Introduction : définition et sources de données
- Stratégies d'analyse statistique
- Biais dans les études pharmaco-épidémiologiques
- Focus sur le biais de confusion mesurée ou non

Examen

Devoir à la maison (lecture critique d'un article)

Séances

Séance 1. Introduction et stratégies d'analyse (Anne Thiébaut)	16 décembre	9h30-12h30
Séance 2. Biais (Anne Thiébaut)	17 décembre	9h30-12h30

Analyse Causale

Responsable : Emeline Courtois

Objectifs

Émuler des essais randomisés pour analyser des données observationnelles, déceler les biais d'études observationnelles à l'aide de graphiques acycliques dirigés (directed acyclic graphs, DAGs), évaluer l'effet des traitements en vie réelle et en population générale dans les études de pharmacoépidémiologie, effectuer des analyses de médiation : les méthodes d'inférence causale et leurs applications se sont développées et multipliées ces dernières années.

Les objectifs de ce module sont : - d'introduire la notion de causalité au travers de la théorie des DAGs, outil performant de dépistage des biais de sélection ; - de formaliser la causalité, notamment en termes d'indépendance conditionnelle, de l'opérateur "do" et/ou des variables contrefactuelles; - et de présenter l'inférence causale sur données observationnelles. Il s'agit également de montrer comment créer des pseudo-population par la méthode IPW en précisant ses conditions d'applications : cohérence, interchangeabilité conditionnelle, positivité. Ce module développera la décomposition de l'effet causal total en présence d'un médiateur et abordera l'estimation des effets causaux à partir de données de grande dimension.

A l'issue du module, les étudiants seront en mesure de connaître et formaliser les principes de l'approche causale, d'identifier des biais potentiels dans l'évaluation d'effets causaux en situations observationnelle et expérimentale, d'appliquer et construire des modèles marginaux structuraux et des analyses de médiation, de relire de façon critique les protocoles d'étude et les publications. Le cours sera accompagné de TPs où les étudiants apprendront à utiliser les package R dagitty (pour l'identification des biais potentiels à partir d'un DAG) et mediation.

Examen

Devoir à la maison

Séances

Séance 1	6 janvier	9h30-12h30
Séance 2	7 janvier	9h30-12h30
Séance 3	8 janvier	9h30-12h30
Séance 4	9 janvier	9h30-12h30

Séminaires

Responsable : Philippe Broët

Objectifs

Compléter la formation par des séminaires.

Séances

Programme à préciser (du 13 au 16 janvier)